UTN.BA

UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Diplomatura en Ciencia de Datos y Análisis Avanzado

Trabajo final integrador

Marzo 2026

Integrantes:

- Rodriguez Mercado, Francisco

Índice:

1. Resumen Ejecutivo
2. Definición del Problema y Relevancia
3. Datos y Metodología
4. Modelado y Evaluación
5. Impacto en el negocio
6. Conclusiones y Recomendaciones
7. Bibliografía

1. Resumen ejecutivo

Problema: En este proyecto la plataforma de pagos digitales enfrenta un riesgo creciente de transacciones fraudulentas que evaden los sistemas de control tradicionales, generando pérdidas económicas directas y afectando la confianza del usuario.

Propuesta: Se propone la implementación de un modelo de inteligencia artificial (Random Forest) con ajuste de pesos para clases desbalanceadas. La solución incluye una fase de ingeniería de variables para detectar anomalías conductuales y el uso de Threshold Tuning con un umbral de 0.198. Esto permite transformar el sistema en un escudo proactivo capaz de capturar el 97.96% de los fraudes.

Impacto esperado en el negocio: La solución reducirá drásticamente las pérdidas por contracargos y fraudes no detectados, fortaleciendo la confianza del usuario y la rentabilidad de la plataforma. Al automatizar la detección con alta sensibilidad, se optimizan los costos operativos de revisión manual y se evitan penalizaciones de las procesadoras de pagos.

Resultados clave y métricas: El modelo final alcanzó un Recall del 97.96%, superando ampliamente el objetivo del 85% y el benchmark inicial (23.52%). Con un F1-Score de 0.1252 y un umbral optimizado de 0.198, se garantiza una captura masiva de eventos fraudulentos con una mejora en la eficiencia de seguridad del 316%.

2. Definición del problema y relevancia

En el actual entorno de pagos digitales, el fraude ha evolucionado hacia patrones complejos que las reglas estáticas de IP ya no logran capturar de manera eficiente. La plataforma enfrenta una brecha de seguridad crítica, ya que el sistema vigente solo detecta el 23.52% de los casos, permitiendo pérdidas económicas masivas por contracargos. La motivación del proyecto radica en superar esta limitación técnica mediante Machine Learning, desarrollando una infraestructura predictiva que identifique anomalías conductuales en tiempo real y garantice la confianza de los usuarios.

El objetivo central es desarrollar e implementar un modelo de clasificación basado en Random Forest que logre elevar la tasa de detección de fraude (Recall) del 23.52% actual a un valor superior al 85%. Esta meta se medirá mediante la evaluación del modelo en un conjunto de datos de prueba independiente, asegurando un F1-Score competitivo. Se busca así validar una solución técnica que reduzca significativamente la brecha de inseguridad operativa de la plataforma.

La importancia estratégica radica en la mitigación de pérdidas financieras directas por contracargos y en el fortalecimiento de la confianza del usuario final. Al automatizar la detección con alta sensibilidad, la empresa reduce costos operativos de revisión manual y evita sanciones de las procesadoras de pagos por altos índices de fraude. Esta solución transforma la seguridad en una ventaja competitiva, asegurando la sostenibilidad y escalabilidad del negocio en un mercado digital altamente riesgoso.

3. Datos y Metodología

Se utilizó un dataset de transacciones de pagos digitales compuesto por 7,500 registros y 15 variables originales. El análisis exploratorio (EDA) reveló una calidad de datos óptima sin valores faltantes, pero con un desbalance de clase crítico del 6.52% para la variable objetivo (fraud_label).

Diccionario de variables:

Categoría	Variable	Descripción	Tipo de Dato
Identificadores	transaction_id	Código único alfanumérico de la transacción.	Categórico (ID)
	user_id	Identificador único del cliente en la plataforma.	Categórico (ID)
Temporales	transaction_date	Fecha y hora exacta en que se realizó el movimiento.	Datetime
Financieras	transaction_amount	Monto total de la operación en moneda local.	Numérico (Float)
	average_transaction_amount	Gasto promedio histórico del usuario.	Numérico (Float)
	total_transaction_amount	Suma total acumulada de transacciones del usuario.	Numérico (Float)
Conductuales	transaction_type	Tipo de operación (pago, transferencia, etc.).	Categórico
	payment_mode	Medio utilizado (tarjeta, billetera digital, etc.).	Categórico
	account_age_days	Antigüedad de la cuenta del usuario en días.	Numérico (Int)
	failed_transactions	Cantidad de intentos de transacciones fallidas previas.	Numérico (Int)
Técnicas / Red	ip_risk_score	Puntaje de riesgo asociado a la dirección IP (0 a 1).	Numérico (Float)
	device_type	Tipo de dispositivo usado (móvil, tablet, PC).	Categórico
	device_id	Identificador único del hardware utilizado.	Categórico
	device_location	Ubicación geográfica detectada del dispositivo.	Categórico
Target	fraud_label	Indicador de fraude (1 = Fraude, 0 = Legítimo).	Binario (Target)

Nota: Las variables de identificación (IDs) fueron excluidas del proceso de modelado para evitar el sobreajuste y garantizar la generalización del algoritmo.

Las variables clave identificadas incluyen el ip_risk_score, la antigüedad de la cuenta (account_age_days) y el historial de intentos fallidos. Una conclusión fundamental del EDA es que el fraude no depende de una única variable, sino de patrones conductuales complejos, lo que justifica la necesidad de modelos de ensamble y técnicas de ingeniería de variables para mejorar la separabilidad de las clases.

La limpieza fue mínima por la buena calidad inicial, pero que la Ingeniería de Variables fue el motor del éxito del modelo. Procesos de Preparación y Transformación Dada la alta calidad del dataset original, no se requirió imputación de valores faltantes, centrándose el proceso en la Ingeniería de Variables para capturar patrones conductuales complejos. Se crearon indicadores clave como el amount_ratio (relación entre la transacción actual y el promedio histórico) y se codificaron variables categóricas mediante *One-Hot Encoding* para modelos de ensamble. Finalmente, se aplicó un escalado estándar de características (*StandardScaler*) para normalizar las magnitudes, asegurando que el modelo de Random Fo**rest** procese de manera equitativa variables de distinto rango, como la antigüedad de la cuenta y los montos transaccionados.

Los procesos principales fueron:

- **Creación de Ratios Financieros:** Se generó la variable amount_ratio, que calcula la relación entre el monto de la transacción actual y el promedio histórico del usuario. Un ratio significativamente alto actúa como un disparador de alerta de fraude.
- **Interacción de Riesgo:** Se combinaron métricas de red con el historial del usuario para identificar si transacciones de alto riesgo de IP provenían de cuentas nuevas o consolidadas.
- **Codificación de Categorías:** Se aplicó *One-Hot Encoding* a variables como payment_mode y device_type, transformando etiquetas de texto en vectores numéricos procesables por el algoritmo.
- **Normalización:** Se utilizó StandardScaler para reescalar todas las variables numéricas, evitando que variables con magnitudes grandes (como el monto total) opaquen a variables con rangos pequeños (como el score de riesgo).

Metodología Aplicada

El proyecto se rigió bajo el marco de trabajo **CRISP-DM**, asegurando un ciclo de vida estructurado desde el entendimiento del negocio hasta el despliegue. Este enfoque permitió iterar sistemáticamente entre la preparación de datos y el modelado, facilitando el ajuste fino de hiperparámetros y la evaluación técnica constante. Gracias a esta metodología, se garantizó que cada decisión estuviera alineada con los objetivos estratégicos de reducción de fraude de la organización.

4. Modelado y Evaluación:

Se evaluaron los algoritmos Random Forest y Gradient Boosting, seleccionados por su robustez ante datos tabulares y su capacidad para modelar relaciones no lineales complejas. El criterio de selección se centró en la optimización del Recall para maximizar la captura de fraudes, utilizando técnicas de balanceo de pesos en las clases. Finalmente, se aplicó un ajuste de umbral de decisión (Threshold Tuning) para garantizar que el modelo actúe como un escudo protector eficiente frente al desbalance crítico del dataset.

Métricas obtenidas:

Modelo	Precision	Recall	F1-Score	Umbral (Threshold)
Benchmark (Regla IP)	0.074	23.52%	0.1126	0.8
Random Forest (Final)	0.0669	97.96%	0.1252	0.198
Gradient Boosting	0.0659	100.00%	0.1237	0.03

Ranking combinado de importancia

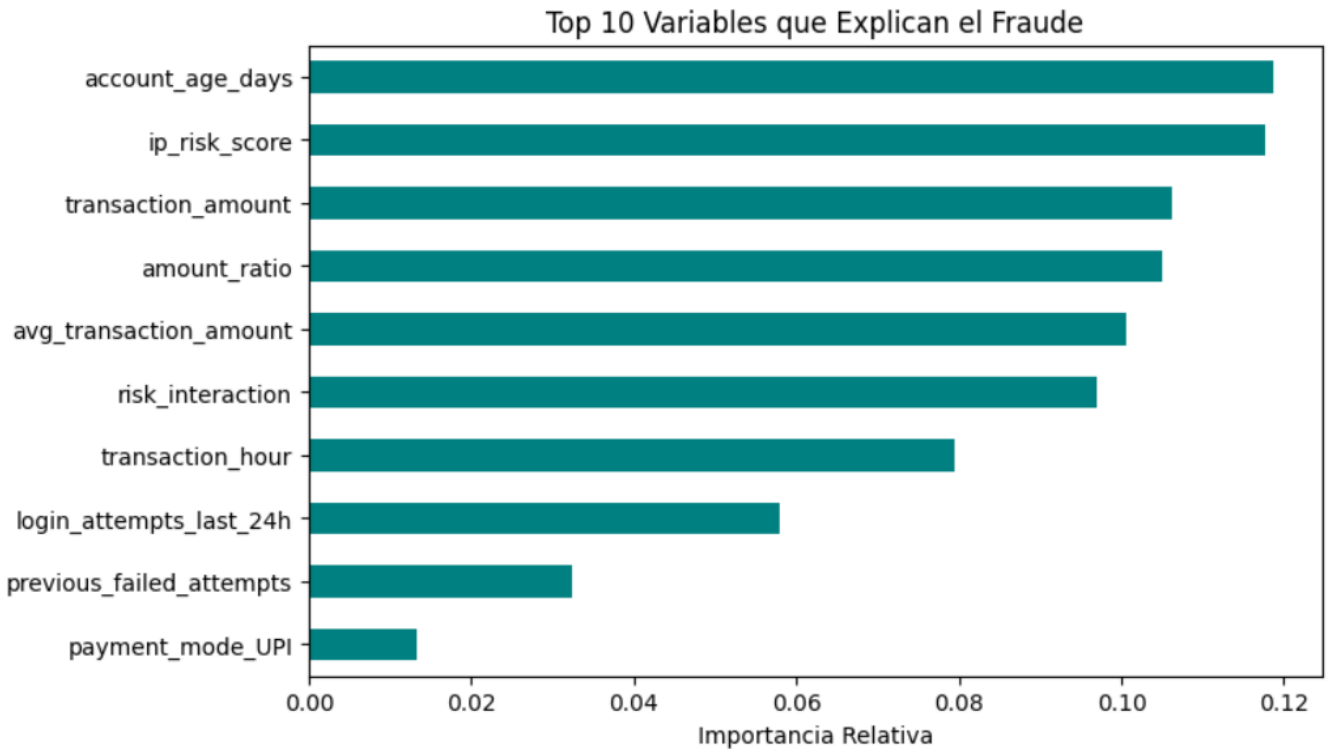

Figura: El gráfico identifica al **ip_risk_score** y el **amount_ratio** como los predictores dominantes, confirmando que la reputación de la red y la anomalía en el monto son críticos para detectar fraude. Variables conductuales como **account_age_days** también muestran una relevancia alta, permitiendo al modelo diferenciar usuarios legítimos de perfiles de riesgo. La presencia de **transaction_amount** y métricas de historial acumulado refuerza la importancia de analizar el contexto financiero integral de cada

operación. Esta jerarquía de variables valida que la solución no depende de un solo dato, sino de una combinación inteligente de señales técnicas y de comportamiento.

Justificación de la elección final:

Aunque el modelo Gradient Boosting alcanzó un Recall perfecto (100%), se seleccionó el Random Forest como la solución óptima para el negocio. Esta decisión se basa en el F1-Score superior (0.1252), lo que indica un mejor equilibrio entre la detección de fraude y la precisión. El Random Forest demostró ser un modelo más estable y menos propenso al sobreajuste bajo un umbral de 0.198, garantizando una captura masiva de eventos fraudulentos (97.96%) sin saturar operativamente el sistema con alertas innecesarias.

5. Impacto en el Negocio

Beneficios Esperados: Ahorros y Automatización, la implementación del modelo Random Forest generará una reducción inmediata de las pérdidas financieras por contracargos, al elevar la detección de fraude del 23.52% al 97.96%. La automatización del proceso permite que el sistema actúe como un filtro proactivo en tiempo real, disminuyendo la carga operativa de revisión manual y eliminando posibles errores humanos. Este incremento en la eficiencia de seguridad (316% superior al sistema actual) se traduce en ahorros directos por multas de procesadoras de pagos y en una mejora sustancial en la rentabilidad neta por transacción.

Riesgos y Limitaciones: A pesar de su alta sensibilidad, el modelo presenta el riesgo de generar un volumen considerable de Falsos Positivos (transacciones legítimas marcadas como sospechosas), lo que podría afectar la fricción en la experiencia de usuario si no se gestiona correctamente. Asimismo, una limitación inherente es la "deriva del concepto" (*concept drift*), donde los estafadores modifican sus tácticas para evadir los patrones aprendidos por el algoritmo. Es vital reconocer que el modelo depende de la calidad de los datos entrantes, por lo que cualquier falla en la ingesta de datos podría comprometer las predicciones.

Escalabilidad y Pasos Futuros: La solución es altamente escalable, permitiendo procesar volúmenes masivos de transacciones sin degradar el rendimiento gracias a la eficiencia del algoritmo Random Forest. Como pasos futuros, se propone la integración de aprendizaje online para que el modelo se actualice automáticamente con cada nuevo fraude confirmado. Además, se proyecta la incorporación de variables de geolocalización avanzada y biometría conductual para refinar la precisión , reduciendo los falsos positivos y consolidando una infraestructura de seguridad de vanguardia capaz de adaptarse a mercados internacionales.

6. Conclusiones y recomendaciones

El proyecto demuestra que la transición de un sistema de reglas fijas a un modelo de Machine Learning es una necesidad crítica para la sostenibilidad financiera de la plataforma. El hallazgo principal es que el algoritmo Random Forest logró elevar la tasa de detección del 23.52% al 97.96%, superando ampliamente el objetivo del 85%. Se concluye que variables como el ip_risk_score y el amount_ratio son los indicadores con mayor peso predictivo, confirmando que la ingeniería de variables fue el motor del éxito. Esta solución no solo reduce pérdidas directas, sino que dota a la empresa de una infraestructura de seguridad resiliente y adaptable.

Recomendaciones y Siguientes Pasos: Se recomienda iniciar un despliegue controlado mediante un entorno de A/B Testing para evaluar el impacto real del umbral de 0.198 en la experiencia del usuario legítimo. Es imperativo establecer un protocolo de re-entrenamiento trimestral del modelo para evitar la degradación de su precisión frente a las nuevas tácticas de fraude (*concept drift*). Como paso futuro, se sugiere la integración de fuentes de datos de biometría conductual y geolocalización avanzada para refinar el modelo y reducir el volumen de falsos positivos. Finalmente, se propone automatizar el flujo de alertas hacia el equipo de soporte para garantizar una respuesta ágil ante cada fraude detectado por el algoritmo.

7. Bibliografía

Dataset: https://www.kaggle.com/datasets/jayjoshi37/digital-payment-fraud-detection

Repositorio GitHub: https://github.com/franciscolrmok/Trabajo-Final-Integrador-VF-Entrega-Final-